

先来定义特征到结果的输出函数为：

$$u = \boldsymbol{\omega}^T \boldsymbol{x} + b$$

接着，我们回忆一下原始优化问题，如下：

$$\begin{aligned} \min & \frac{1}{2} \|\boldsymbol{\omega}\|^2 \\ \text{s.t. } & y_i (\boldsymbol{\omega}^T \boldsymbol{x}_i + b) \geq 1, i = 1, 2, \dots, n \end{aligned}$$

求导得：

$$\boldsymbol{\omega} = \sum_{i=1}^n \alpha_i y_i \boldsymbol{x}_i$$

将上述公式带入输出函数中：

$$u = \sum_{i=1}^n \alpha_i y_i \boldsymbol{x}_i^T \boldsymbol{x} + b$$

与此同时，拉格朗日对偶后得到最终的目标化函数：

$$\begin{aligned} \max_{\boldsymbol{\alpha}} & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j \boldsymbol{x}_i^T \boldsymbol{x}_j \\ \text{s.t. } & \alpha_i \geq 0, i = 1, 2, \dots, n \\ & \sum_{i=1}^n \alpha_i y_i = 0 \end{aligned}$$

将目标函数变形，在前面增加一个符号，将最大值问题转换成最小值问题：

$$\begin{aligned} \min_{\boldsymbol{\alpha}} & \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \boldsymbol{x}_i^T \boldsymbol{x}_j - \sum_{i=1}^n \alpha_i \\ \text{s.t. } & \alpha_i \geq 0, i = 1, 2, \dots, n \\ & \sum_{i=1}^n \alpha_i y_i = 0 \end{aligned}$$

实际上，对于上述目标函数，是存在一个假设的，即数据100%线性可分。但是，目前为止，我们知道几乎所有数据都不那么"干净"。这时我们就可以的**松弛变量**(slack variable)，来允许有些数据点可以处于超平面的错误的一侧。这样我们的优化目标就能保持仍然不变，但是此时我们的约束条件有所改

$$\begin{aligned} \text{s.t. } & C \geq \alpha_i \geq 0, i = 1, 2, \dots, n \\ & \sum_{i=1}^n \alpha_i y_i = 0 \end{aligned}$$

根据KKT条件可以得出其中 α_i 取值的意义为：

$$\alpha_i = 0 \Leftrightarrow y_i u_i \geq 1$$

$$0 < \alpha_i < C \Leftrightarrow y_i u_i = 1$$

$$\alpha_i = C \Leftrightarrow y_i u_i \leq 1$$

- 对于第1种情况，表明 α_i 是正常分类，在边界内部；
- 对于第2种情况，表明 α_i 是支持向量，在边界上；
- 对于第3种情况，表明 α_i 是在两条边界之间。

而最优解需要满足KKT条件，即上述3个条件都得满足，以下几种情况出现将会不满足：

$$y_i u_i \leq 1 \quad \alpha_i < C$$

$$y_i u_i \geq 1 \quad \alpha_i > 0$$

$$y_i u_i = 1 \quad \alpha_i = 0 \text{ 或者 } \alpha_i = C$$

也就是说，如果存在不能满足KKT条件的 α_i ，那么需要更新这些 α_i ，这是第一个约束条件。此外，更新的同时还要受到第二个约束条件的限制，即：

$$\sum_{i=1}^n \alpha_i y_i = 0$$

因为这个条件，我们同时更新两个 α 值，因为只有成对更新，才能保证更新之后的值仍然满足和为0的约束，假设我们选择的两个乘子为 α_1 和 α_2 ：

$$\alpha_1^{new} y_1 + \alpha_2^{new} y_2 = \alpha_1^{old} y_1 + \alpha_2^{old} y_2 = \zeta$$

其中， ζ 为常数。因为两个因子不好同时求解，所以可以先求第二个乘子 α_2 的解（ α_2^{new} ），得到 α_2 的解（ α_2^{new} ）之后，再用 α_2 的解（ α_2^{new} ）解（ α_1^{new} ）。为了求解 α_2^{new} ，得先确定 α_2^{new} 的取值范围。假设它的上下边界分别为H和L，那么有：

$$L \leq \alpha_2^{new} \leq H$$

接下来，综合下面两个条件：

$$C \geq \alpha_i \geq 0, \quad i = 1, 2, \dots, n$$

$$\alpha_1^{new} y_1 + \alpha_2^{new} y_2 = \alpha_1^{old} y_1 + \alpha_2^{old} y_2 = \zeta$$


当 $y_1 \neq y_2$ 时，即一个为正1，一个为负1的时候，可以得到：

$$\alpha_1^{old} - \alpha_2^{old} = \zeta$$

所以有：

$$L = \max(0, -\zeta), \quad H = \min(C, C - \zeta)$$

此时，取值范围如下图所示：




当 y_1 等于 y_2 时，即两个都为正1或者都为负1，可以得到：

$$\alpha_1^{old} + \alpha_2^{old} = \zeta$$

所以有：

$$L = \max(0, \zeta - C), \quad H = \min(C, \zeta)$$

此时，取值范围如下图所示：



如此，根据 y_1 和 y_2 异号或同号，可以得出 α_2 new的上下界分别为：

$$\begin{cases} L = \max(0, \alpha_2^{old} - \alpha_1^{old}), H = \min(C, C + \alpha_2^{old} - \alpha_1^{old}) & \text{if } y_1 \neq y_2 \\ L = \max(0, \alpha_2^{old} + \alpha_1^{old} - C), H = \min(C, \alpha_2^{old} + \alpha_1^{old}) & \text{if } y_1 = y_2 \end{cases}$$

这个界限就是编程的时候需要用到的。已经确定了边界，接下来，就是推导迭代式，用于更新 α 值。

我们已经知道，更新 α 的边界，接下来就是讨论如何更新 α 值。我们依然假设选择的两个乘子为 α_1 和 α_2 。固定这两个乘子，进行推导。于是目标函数

$$\begin{aligned}
W(a_2) &= \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n y_i y_j \mathbf{x}_i^T \mathbf{x}_j \alpha_i \alpha_j \\
&= \alpha_1 + \alpha_2 + \sum_{i=3}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \left(\sum_{j=1}^2 y_i y_j \alpha_i \alpha_j \mathbf{x}_i^T \mathbf{x}_j + \sum_{j=3}^n y_i y_j \alpha_i \alpha_j \mathbf{x}_i^T \mathbf{x}_j \right) \\
&= \alpha_1 + \alpha_2 + \sum_{i=3}^n \alpha_i - \frac{1}{2} \sum_{i=1}^2 \left(\sum_{j=1}^2 y_i y_j \alpha_i \alpha_j \mathbf{x}_i^T \mathbf{x}_j + \sum_{j=3}^n y_i y_j \alpha_i \alpha_j \mathbf{x}_i^T \mathbf{x}_j \right) \\
&\quad - \frac{1}{2} \sum_{i=3}^n \left(\sum_{j=1}^2 y_i y_j \alpha_i \alpha_j \mathbf{x}_i^T \mathbf{x}_j + \sum_{j=3}^n y_i y_j \alpha_i \alpha_j \mathbf{x}_i^T \mathbf{x}_j \right) \\
&= \alpha_1 + \alpha_2 + \sum_{i=3}^n \alpha_i - \frac{1}{2} \sum_{i=1}^2 \sum_{j=1}^2 y_i y_j \alpha_i \alpha_j \mathbf{x}_i^T \mathbf{x}_j - \sum_{i=1}^2 \sum_{j=3}^n y_i y_j \alpha_i \alpha_j \mathbf{x}_i^T \mathbf{x}_j \\
&\quad - \frac{1}{2} \sum_{i=3}^n \sum_{j=3}^n y_i y_j \alpha_i \alpha_j \mathbf{x}_i^T \mathbf{x}_j \\
&= \alpha_1 + \alpha_2 - \frac{1}{2} \alpha_1^2 \mathbf{x}_1^T \mathbf{x}_1 - \frac{1}{2} \alpha_2^2 \mathbf{x}_2^T \mathbf{x}_2 - y_1 y_2 \alpha_1 \alpha_2 \mathbf{x}_1^T \mathbf{x}_2 - y_1 \alpha_1 \sum_{j=3}^n \alpha_j y_j \mathbf{x}_1^T \mathbf{x}_j \\
&\quad - y_2 \alpha_2 \sum_{j=3}^n \alpha_j y_j \mathbf{x}_2^T \mathbf{x}_j + \sum_{i=3}^n \alpha_i - \frac{1}{2} \sum_{i=3}^n \sum_{j=3}^n y_i y_j \alpha_i \alpha_j \mathbf{x}_i^T \mathbf{x}_j
\end{aligned}$$

为了描述方便，我们定义如下符号：

$$\begin{aligned}
f(\mathbf{x}_i) &= \sum_{j=1}^n \alpha_j y_j \mathbf{x}_i^T \mathbf{x}_j + b \\
v_i &= \sum_{j=3}^n \alpha_j y_j \mathbf{x}_i^T \mathbf{x}_j = f(\mathbf{x}_i) - \sum_{j=1}^2 \alpha_j y_j \mathbf{x}_i^T \mathbf{x}_j - b
\end{aligned}$$

最终目标函数变为：

$$\begin{aligned}
W(a_2) &= \alpha_1 + \alpha_2 - \frac{1}{2} \alpha_1^2 \mathbf{x}_1^T \mathbf{x}_1 - \frac{1}{2} \alpha_2^2 \mathbf{x}_2^T \mathbf{x}_2 - y_1 y_2 \alpha_1 \alpha_2 \mathbf{x}_1^T \mathbf{x}_2 - y_1 \alpha_1 v_1 - y_2 \alpha_2 v_2 \\
&\quad + \text{constant}
\end{aligned}$$

我们不关心constant的部分，因为对于 α_1 和 α_2 来说，它们都是常数项，在求导的时候，直接变为0。对于这个目标函数，如果对其求导，还有个未知推导出 α_1 和 α_2 的关系，然后用 α_2 代替 α_1 ，这样目标函数就剩一个未知数了，我们就可以求导了，推导出迭代公式。所以现在继续推导 α_1 和 α_2 的关系。注条件：

$$\sum_{i=1}^n \alpha_i y_i = 0$$

我们在求 α_1 和 α_2 的时候，可以将 $\alpha_3, \alpha_4, \dots, \alpha_n$ 和 y_3, y_4, \dots, y_n 看作常数项。因此有：

$$\alpha_1 y_1 + \alpha_2 y_2 = B$$

我们不必关心常数B的大小，现在将上述等式两边同时乘以 y_1 ，得到($y_1 y_1 = 1$)：

$$\alpha_1 = \gamma - s \alpha_2$$

其中 γ 为常数 $B y_1$ ，我们不关心这个值， $s = y_1 y_2$ 。接下来，我们将得到的 α_1 带入 $W(a_2)$ 公式得：

$$\begin{aligned}
W(a_2) &= \gamma - s \alpha_2 + \alpha_2 - \frac{1}{2} (\gamma - s \alpha_2)^2 \mathbf{x}_1^T \mathbf{x}_1 - \frac{1}{2} \alpha_2^2 \mathbf{x}_2^T \mathbf{x}_2 - s (\gamma - s \alpha_2) \alpha_2 \mathbf{x}_1^T \mathbf{x}_2 \\
&\quad - y_1 (\gamma - s \alpha_2) v_1 - y_2 \alpha_2 v_2 + \text{constant}
\end{aligned}$$

这样目标函数中就只剩下 α_2 了，我们对其求偏导（注意： $s = y_1 y_2$ ，所以 s 的平方为1， y_1 的平方和 y_2 的平方均为1）：

$$\begin{aligned}
\frac{\partial W(a_2)}{\partial \alpha_2} &= -s + 1 + \gamma s \mathbf{x}_1^T \mathbf{x}_1 - \alpha_2 \mathbf{x}_1^T \mathbf{x}_1 - \alpha_2 \mathbf{x}_2^T \mathbf{x}_2 \\
&\quad - \gamma s \mathbf{x}_1^T \mathbf{x}_2 + 2 \alpha_2 \mathbf{x}_1^T \mathbf{x}_2 + y_2 v_1 - y_2 v_2 = 0
\end{aligned}$$

继续化简，将 $s = y_1 y_2$ 带入方程。

$$\alpha_2^{\text{new}} = \frac{y_2 (y_2 - y_1 + y_1 \gamma (\mathbf{x}_1^T \mathbf{x}_1 - \mathbf{x}_1^T \mathbf{x}_2)) + v_1 - v_2}{\mathbf{x}_1^T \mathbf{x}_1 + \mathbf{x}_2^T \mathbf{x}_2 - 2 \mathbf{x}_1^T \mathbf{x}_2}$$

我们令：

$$E_i = f(x_i) - y_i$$

$$\eta = \mathbf{x}_1^T \mathbf{x}_1 + \mathbf{x}_2^T \mathbf{x}_2 - 2\mathbf{x}_1^T \mathbf{x}_2$$

E_i 为误差项， η 为学习速率。

再根据我们已知的公式：

$$\gamma = \alpha_1^{old} + s\alpha_2^{old}$$

$$v_j = \sum_{i=3}^n \alpha_i y_i \mathbf{x}_j^T \mathbf{x}_i = f(\mathbf{x}_j) - \sum_{i=1}^2 \alpha_i y_i \mathbf{x}_j^T \mathbf{x}_i - b$$

将 α_2^{new} 继续化简得：

$$\alpha_2^{new} = \alpha_2^{old} + \frac{y_2(E_1 - E_2)}{\eta}$$

这样，我们就得到了最终需要的迭代公式。这个是没有经过剪辑的解，需要考虑约束：

$$0 < \alpha_i < C$$

根据之前推导的 α 取值范围，我们得到最终的解析解为：

$$\alpha_2^{new,clipped} = \begin{cases} H & \alpha_2^{new} > H \\ \alpha_2^{new} & L \leq \alpha_2^{new} \leq H \\ L & \alpha_2^{new} < L \end{cases}$$

又因为：

$$\alpha_1^{old} = \gamma - s\alpha_2^{old}$$

$$\alpha_1^{new} = \gamma - s\alpha_2^{new,clipped}$$

消去 γ 得：

$$\alpha_1^{new} = \alpha_1^{old} + y_1 y_2 (\alpha_2^{old} - \alpha_2^{new,clipped})$$

这样，我们就知道了怎样计算 α_1 和 α_2 了，也就是如何对选择的 α 进行更新。

当我们更新了 α_1 和 α_2 之后，需要重新计算阈值 b ，因为 b 关系到了我们 $f(x)$ 的计算，也就关系到了误差 E_i 的计算。

我们要根据 α 的取值范围，去更正 b 的值，使间隔最大化。当 α_1^{new} 在0和C之间的时候，根据KKT条件可知，这个点是支持向量上的点。因此，满足

$$y_1(\omega^T \mathbf{x}_1 + b) = 1$$

公式两边同时乘以 y_1 得($y_1 y_1 = 1$)：

$$\sum_{i=1}^n \alpha_i y_i \mathbf{x}_i^T \mathbf{x}_1 + b = y_1$$

因为我们是根据 α_1 和 α_2 的值去更新 b ，所以单独提出 $i=1$ 和 $i=2$ 的时候，整理可得：

$$b_1^{new} = y_1 - \sum_{i=3}^n \alpha_i y_i \mathbf{x}_i^T \mathbf{x}_1 - \alpha_1^{new} y_1 \mathbf{x}_1^T \mathbf{x}_1 - \alpha_2^{new} y_2 \mathbf{x}_2^T \mathbf{x}_1$$

其中前两项为：

$$y_1 - \sum_{i=3}^n \alpha_i y_i \mathbf{x}_i^T \mathbf{x}_1 = -E_1 + \alpha_1^{old} y_1 \mathbf{x}_1^T \mathbf{x}_1 + \alpha_2^{old} y_2 \mathbf{x}_2^T \mathbf{x}_1 + b^{old}$$

将上述两个公式，整理得：

$$b_1^{new} = b^{old} - E_1 - y_1(\alpha_1^{new} - \alpha_1^{old})\mathbf{x}_1^T \mathbf{x}_1$$

$$- y_2(\alpha_2^{new} - \alpha_2^{old})\mathbf{x}_2^T \mathbf{x}_1$$

同理可得 b_2 new为：

$$b_2^{new} = b^{old} - E_2 - y_1(\alpha_1^{new} - \alpha_1^{old})\mathbf{x}_1^T \mathbf{x}_2 - y_2(\alpha_2^{new} - \alpha_2^{old})\mathbf{x}_2^T \mathbf{x}_2$$

当 b_1 和 b_2 都有效的时候，它们是相等的，即：

$$b^{new} = b_1^{new} = b_2^{new}$$

当两个乘子都在边界上，则 b 阈值和KKT条件一致。当不满足的时候，SMO算法选择他们的中点作为新的阈值：

$$b = \begin{cases} b_1, & 0 < \alpha_1^{new} < C \\ b_2 & 0 < \alpha_2^{new} < C \\ (b_1 + b_2)/2 & \text{otherwise} \end{cases}$$

最后，更新所有的 α 和 b ，这样模型就出来了，从而即可求出我们的分类函数。

现在，让我们梳理下SMO算法的步骤：

- 步骤1：计算误差：

$$E_i = f(\mathbf{x}_i) - y_i = \sum_{j=1}^n \alpha_j y_j \mathbf{x}_i^T \mathbf{x}_j + b - y_i$$

- 步骤2：计算上下界 L 和 H ：

$$\begin{cases} L = \max(0, \alpha_j^{old} - \alpha_i^{old}), H = \min(C, C + \alpha_j^{old} - \alpha_i^{old}) & \text{if } y_i \neq y_j \\ L = \max(0, \alpha_j^{old} + \alpha_i^{old} - C), H = \min(C, \alpha_j^{old} + \alpha_i^{old}) & \text{if } y_i = y_j \end{cases}$$

- 步骤3：计算 η ：

$$\eta = \mathbf{x}_i^T \mathbf{x}_i + \mathbf{x}_j^T \mathbf{x}_j - 2\mathbf{x}_i^T \mathbf{x}_j$$

- 步骤4：更新 α_j ：

$$\alpha_j^{new} = \alpha_j^{old} + \frac{y_j(E_i - E_j)}{\eta}$$

- 步骤5：根据取值范围修剪 α_j ：

$$\alpha_j^{new,clipped} = \begin{cases} H & \text{if } \alpha_j^{new} \geq H \\ \alpha_j^{new} & \text{if } L \leq \alpha_j^{new} \leq H \\ L & \text{if } \alpha_j^{new} \leq L \end{cases}$$

- 步骤6：更新 α_i ：

$$\alpha_i^{new} = \alpha_i^{old} + y_i y_j (\alpha_j^{old} - \alpha_j^{new,clipped})$$

- 步骤7：更新 b_1 和 b_2 ：

$$\begin{aligned} b_1^{new} &= b^{old} - E_i - y_i(\alpha_i^{new} - \alpha_i^{old})\mathbf{x}_i^T \mathbf{x}_i - y_j(\alpha_j^{new} - \alpha_j^{old})\mathbf{x}_j^T \mathbf{x}_i \\ b_2^{new} &= b^{old} - E_j - y_i(\alpha_i^{new} - \alpha_i^{old})\mathbf{x}_i^T \mathbf{x}_j - y_j(\alpha_j^{new} - \alpha_j^{old})\mathbf{x}_j^T \mathbf{x}_j \end{aligned}$$

- 步骤8：根据 b_1 和 b_2 更新 b ：

$$b = \begin{cases} b_1 & 0 < \alpha_1^{new} < C \\ b_2 & 0 < \alpha_2^{new} < C \\ \frac{b_1 + b_2}{2} & \text{otherwise} \end{cases}$$